NHẬN DIỆN SỰ KIỆN TRONG ALBUM ẢNH SỬ DỤNG MÔ HÌNH TRANSFORMER ATTENTION

Đồ án cuối kỳ - CTT451 Nhập môn Thị giác máy tính

Nguyễn Hoàng Gia Bảo - 23127157, Nguyễn Huỳnh Tiến - 23127494

***Tóm tắt nội dung*—Nhu cầu quản lý số lượng lớn ảnh dưới dạng album gia tăng kéo theo sự cần thiết của một hệ thống tự động phân loại và quản lý những album này dựa theo sự kiện (event) của chúng. Khó khăn lớn nhất mà bài toán đối mặt là các ảnh nhiễu (irrelevant images) trong album, yêu cầu mô hình cần phải nắm được ngữ cảnh toàn cục của toàn album. Điều mà các phương pháp trước đó (như Convolution Neural Network (CNN) + Average Pooling) chưa thể giải quyết triệt để. Để giải quyết vấn đề trên, đồ án đề xuất phương pháp tiếp cận bài toán dựa trên kiến trúc PETA (Photo Albums Event Recognition using Transformers Attention) [1]. Thay vì xử lý riêng lẻ từng ảnh, kiến trúc PETA áp dụng cơ chế Self-Attention để nắm bắt ngữ cảnh toàn cục của album, phát hiện và tránh ảnh hưởng bởi thông tin từ các ảnh nhiễu. Kết quả thực nghiệm mong muốn sẽ chứng minh kiến trúc PETA mang lại độ chính xác vượt trội so với các mô hình cơ sở, khẳng định tính hiệu quả trong việc lọc nhiễu của cơ chế Attention trong kiến trúc Transformer.**

I. GIỚI THIỆU

NGÀY nay, các thiết bị di động trở nên vô cùng phổ biến, người dùng dễ dàng chụp hàng chục đến hàng trăm bức ảnh cho một sự kiện nào đó và lưu chúng thành một album. Việc con người tự phân loại các album này mất rất nhiều thời gian. Dẫn đến sự cần thiết của một hệ thống tự động nhận diện sự kiện trong các album ảnh.

Khó khăn gặp phải khi giải quyết bài toán này là sự xuất hiện của các ảnh nhiễu (như ảnh mờ, ảnh chụp cận cảnh đồ vật hoặc các bối cảnh không đặc trưng của sự kiện). Do đó, một hệ thống hiệu quả cần có khả năng nắm bắt ngữ cảnh toàn cục trong toàn album, từ đó chọn lọc thông tin để đưa ra dự đoán chính xác.

II. CÁC CÔNG TRÌNH LIÊN QUAN

Để giải quyết bài toán nhận dạng sự kiện trong album ảnh, nhiều hướng tiếp cận đã được đề xuất:

- **Hướng tiếp cận dựa trên Feature Pooling:**
  - Sử dụng các mô hình CNN (như VGG hoặc ResNet) để trích xuất đặc trưng cho từng ảnh, sau đó sử dụng Pooling (như Average Pooling hoặc Max Pooling) để tổng hợp thành một vector đại diện cho toàn bộ album [2].
  - Nhược điểm: Gán trọng số ngang nhau cho mọi bức ảnh, khiến mô hình bị ảnh hưởng mạnh bởi ảnh nhiễu, làm giảm độ chính xác của mô hình.
- **Hướng tiếp cận theo chuỗi ảnh (Sequence-based Models):**
  - Coi album ảnh như một chuỗi có thứ tự (tương tự video) bằng cách sắp xếp các bức ảnh theo trình tự thời gian, sau đó sử dụng các mô hình (như RNN hoặc LSTM) để khai thác tính liên tục của sự kiện [3], [4].
  - Nhược điểm: Các bức ảnh có tính rời rạc cao và thứ tự thời gian đôi khi không giống với một video. Hiệu năng mô hình giảm mạnh trong những trường hợp như các ảnh bị xáo trộn thứ tự.
- **Hướng tiếp cận bằng mạng đồ thị (Graph Neural Networks):**
  - Biểu diễn album dưới dạng một đồ thị, trong đó mỗi bức ảnh là một node và các cạnh thể hiện mức độ tương đồng giữa các ảnh. Cập nhật đặc trưng của từng ảnh dựa trên ngữ cảnh lân cận, thể hiện mối quan hệ giữa các ảnh trong sự kiện [5].
  - Nhược điểm: Độ phức tạp tính toán và yêu cầu bộ nhớ cao ($O(N^2)$). Đòi hỏi tài nguyên cực lớn khi tăng số lượng ảnh trong album.
- **Hướng tiếp cận dựa trên kiến trúc Transformer (Giải pháp đề xuất):** Xem album là một tập không có thứ tự. Kiến trúc tiêu biểu là **PETA (Photo Albums Event Recognition using Transformers Attention)** [1], ứng dụng cơ chế Multi-Head Self-Attention để đánh giá sự tương quan giữa mọi bức ảnh. Từ đó, tự động lọc nhiễu và cải thiện kết quả đầu ra.

III. GIẢI PHÁP ĐỀ XUẤT

A. Mô tả bài toán

Bài toán nhận dạng sự kiện trong album ảnh được xác định như sau:

- **Đầu vào (Input):** Một album cá nhân được biểu diễn dưới dạng tập hợp không có thứ tự

$$X = \{x_1, x_2, \ldots, x_N\}$$

  Cho trước $\mathcal{C}$ là tập nhãn chứa các sự kiện mục tiêu (Đám cưới, Sinh nhật,...).
- **Đầu ra (Output):** Một nhãn sự kiện $Y \in \mathcal{C}$ đại diện chính xác cho ngữ nghĩa của toàn bộ album.

Mục tiêu của bài toán là xây dựng một ánh xạ tối ưu $f : X \to Y$. Giả sử mỗi bức ảnh x_i được trích xuất thành một vector đặc trưng v_i. Các phương pháp pooling truyền thống

thường tính các đặc trưng toàn cục của album bằng trung bình cộng:

$$V_{album} = \frac{1}{N}\sum_{i=1}^{N} v_i$$

Vấn đề là sự tồn tại của các ảnh nhiễu (mờ nét, không mang thông tin đặc trưng cho sự kiện chính) trong tập X. Việc gán trọng số như nhau cho mọi bức ảnh làm giảm độ chính xác của việc dự đoán.

Do đó, bài toán đặt ra yêu cầu mô hình phải học được cách đánh giá mức độ quan trọng của từng ảnh:

$$V^*_{album} = \sum_{i=1}^{N} \alpha_i v_i$$

Yêu cầu tối ưu là $\alpha_i \to 0$ đối với các ảnh nhiễu và α_i đạt giá trị lớn đối với các ảnh mang đặc trưng quan trọng.

B. Tổng quan kiến trúc

Để giải quyết yêu cầu trên, nhóm đề xuất mô hình kiến trúc PETA. Mô hình nhận đầu vào là tập X chứa N hình ảnh và đầu ra là nhãn sự kiện dự đoán.

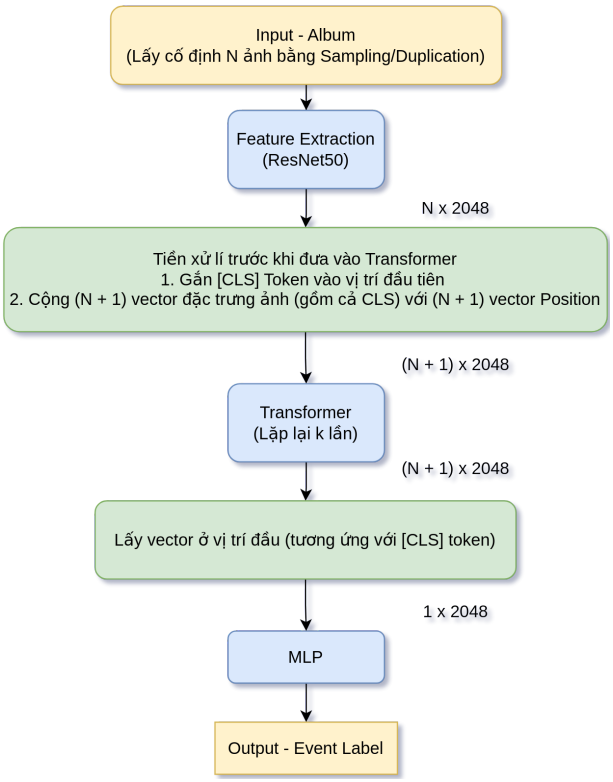

Hình 1. Kiến trúc tổng thể của mô hình PETA.

C. Trích xuất đặc trưng và Tiền xử lý

Sử dụng mô hình ResNet-50 đã được huấn luyện sẵn trên tập ImageNet (bỏ lớp Fully Connected cuối cùng). Mỗi bức ảnh trong album được trích xuất thành một vector đặc trưng có số chiều $d = 2048$. Album ảnh được biểu diễn dưới dạng ma trận kích thước $(N, 2048)$.

Trước khi đưa vào khối Transformer, dữ liệu được tiền xử lý qua hai bước:

- **Gắn [CLS] Token:** Một vector đại diện có thể học được (learnable token) mang thông tin tổng quát của cả album được chèn vào vị trí đầu tiên của ma trận.
- **Positional Encoding:** Chuỗi $(N + 1)$ vector tiếp tục được cộng trực tiếp với ma trận mã hóa vị trí (Position Encoding) để bổ sung thông tin về thứ tự cho mạng Transformer.

D. Khối Transformer Attention

Đây là thành phần chính của mô hình đề xuất, làm nhiệm vụ lọc các ảnh nhiễu. Gồm 2 thành phần Multi-Head Self-Attention kết hợp với mạng truyền thẳng (Feed-Forward Network). Cơ chế Attention cho phép mô hình học được mối tương quan ngữ cảnh giữa tất cả các bức ảnh trong album. Nhờ đó, mô hình tự động điều chỉnh phân bổ trọng số: gán trọng số chú ý lớn cho các bức ảnh quan trọng và giảm sự chú ý đối với các bức ảnh nhiễu.

E. Tổng hợp đặc trưng bằng [CLS] Token & Phân loại

Khác với phương pháp truyền thống (Average Pooling), kiến trúc PETA tổng hợp thông tin sự kiện thông qua [CLS] Token. Sau khi toàn bộ chuỗi đi qua các lớp Transformer, trạng thái cuối cùng của vector ở vị trí đầu tiên (tương ứng với [CLS] token) được trích xuất làm vector đại diện cho toàn bộ album. Sau đó đưa vector này qua khối Multi-Layer Perceptron (MLP) để thực hiện phân loại và tính toán ra nhãn sự kiện cuối cùng.

IV. Thực nghiệm và đánh giá

A. Benchmark Dataset

Thực nghiệm được tiến hành trên tập dữ liệu chuẩn PEC (Photo Event Collection). Tập dữ liệu bao gồm 14 lớp sự kiện khác nhau (như Birthday, Wedding, Graduation...). Tập dữ liệu được chia thành Train/Test với 643/161 album (80%/20%), đảm bảo mô hình không bị Data Leakage.

B. Chi tiết thực nghiệm

Mô hình được cài đặt bằng thư viện PyTorch. Quá trình huấn luyện diễn ra trong 30 epochs với Batch Size = 16. Thuật toán tối ưu được sử dụng Stochastic Gradient Descent (SGD) với Momentum bằng 0.9 và Weight Decay ở mức 1e-3 nhằm kiểm soát tốt hơn quá trình hội tụ.

Tốc độ học (Learning Rate) được khởi tạo là 0.01. Để tối ưu hóa, nhóm sử dụng MultiStepLR, tốc độ học sẽ giảm 10 lần khi qua các epoch thứ 15 và 25. Cuối cùng, hàm mất mát (Loss function) được sử dụng là Cross-Entropy Loss kết hợp Label Smoothing với hệ số 0.1 nhằm giảm nguy cơ Overfitting trên tập dữ liệu nhỏ.

C. Chỉ số đánh giá

Hiệu suất của mô hình được đánh giá qua hai chỉ số chính:

- **Accuracy:** Tỷ lệ phần trăm các album được phân loại đúng sự kiện.
- **mAP (Mean Average Precision):** Trung bình độ chính xác trên tất cả các lớp sự kiện.

D. Phân tích kết quả

Bảng I
KẾT QUẢ THỰC NGHIỆM TRÊN TẬP DỮ LIỆU PEC

Phương pháp	Accuracy (%)	mAP (%)
Baseline (CNN + Avg Pool)	85.96% ± 0.84%	92.99% ± 0.35%
Proposed (PETA)	**89.32% ± 0.82%**	**94.32% ± 0.20%**

Dựa vào kết quả thực nghiệm được trình bày trong Bảng I, ta thấy một số nhận xét quan trọng về hiệu năng cũng như những hạn chế của mô hình đề xuất:

1) **Sự cải thiện về hiệu năng của cơ chế Attention so với phương pháp truyền thống:** Kết quả cho thấy mô hình đề xuất đã cải thiện kết quả khá tốt so với mô hình Baseline (sử dụng Average Pooling). Cụ thể, độ chính xác (Accuracy) tăng từ 85.96% lên 89.32%, và chỉ số mAP tăng từ 92.99% lên 94.32%. Điều này cho thấy cơ chế Multi-Head Self-Attention đã một phần khắc phục được vấn đề ảnh nhiễu so với phương pháp Pooling truyền thống
2) **Hạn chế** Kích thước tập dữ liệu PEC là khá nhỏ so với kiến trúc của mô hình PETA.
   - Kiến trúc Transformer là quá lớn nên khi học trên một tập dữ liệu nhỏ như PEC khiến mô hình này rơi vào trạng thái Overfitting.
   - Để đạt hiệu năng như trình bày ở trên, nhóm phải giảm độ sâu của mô hình, chỉ dùng 2 khối Transformer, cũng như áp dụng nhiều kỹ thuật chống Overfitting như Label Smoothing, Weight Decay, Dropout lên đến 0.5. Điều này làm hạn chế khá nhiều khả năng thật sự của mô hình

   Tuy cải thiện được hiệu năng, nhưng mức cải thiện là không bất ngờ so với sự đánh đổi về độ phức tạp mà mô hình mang lại
   - Trong khi Average truyền thống là vô cùng đơn giản với độ phức tạp chỉ $\mathcal{O}(N)$.
   - Transformer Attention có độ phức tạp lên tới $\mathcal{O}(N^2 \cdot d)$, kéo theo số lượng tham số rất lớn mà mô hình sử dụng. Mô hình PETA là cực kì phức tạp và cồng kềnh so với Average Pooling.

V. KẾT LUẬN

Trong đồ án này, nhóm đã đề xuất và cài đặt thành công mô hình PETA, ứng dụng kiến trúc Transformer vào bài toán nhận dạng sự kiện từ album ảnh. Thay vì sử dụng phương pháp gộp trung bình (Average Pooling) truyền thống vốn dễ bị ảnh hưởng bởi các ảnh nhiễu, việc áp dụng cơ chế Multi-Head Self-Attention đã giúp mô hình lọc và chú ý vào các ảnh quan trọng. Kết quả thực nghiệm trên tập dữ liệu PEC cho thấy mô hình PETA cải thiện hiệu năng tốt so với mô hình Baseline cơ sở.

Tuy nhiên, nghiên cứu cũng chỉ ra hai rào cản lớn khi triển khai Transformer cho bài toán này. Thứ nhất là vấn đề thiếu hụt về dữ liệu: kích thước tập huấn luyện nhỏ khiến mô hình rơi vào tình trạng Overfitting, đòi hỏi phải áp dụng nhiều kỹ thuật điều chỉnh quá trình train. Thứ hai là sự cồng kềnh về độ phức tạp của mô hình, kéo theo yêu cầu khắt khe về tài nguyên phần cứng và thời gian xử lý.

TÀI LIỆU THAM KHẢO

TÀI LIỆU

[1] T. Glaser et al., "Peta: Photo albums event recognition using transformers attention," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, 2021, pp. 1–10.

[2] Y. Guo et al., "Event recognition in photo albums with a group-level feature learning," in *Proceedings of the ACM International Conference on Multimedia*, 2015, pp. 1–10.

[3] X. Wang et al., "Recognizing photo events with sequence-based models," *IEEE Transactions on Multimedia*, vol. 19, no. 5, pp. 1011–1023, 2017.

[4] L. Qi et al., "Discriminative sequence-based models for photo album event recognition," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[5] Z. Guo et al., "Graph neural networks for photo event recognition," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020.